AGI 智能体为什么走不通：生命第一因与通用问题论

序：我换了一个问题

谈人工智能，绝大多数人在谈"它有多强"：参数、算力、多模态、跑分。这些都不假，但它们回答的是"能长到多大"，不是"它凭什么算一个东西"。

我换了一个问题：**一个东西凭什么算活着；活着之后，什么东西才跟着出现。**

我的答案先摆在这里，后面整篇都在证明它：**智慧是生命的结果，心跳是演化的起点。** 顺序只有一个方向——先活着，才谈得上聪明。

一、第一因不是"设计出来的"

讲生命，第一句常被讲歪。我把三层分开，顺序不许换。

第一层是物理前提。 原料、环境、那一次偶然的自我复制——核酸分子、可用的能量、稳定的温度、足够长的时间。这些东西先满足，才谈得上"开始"。那一次偶然很重要，但它只解释"怎么开始"，不解释"为什么继续"。把它当第一因，是把前提当成了原因。

第二层才是第一因：为了维持这次复制，也就是为了存活。 复制发生了一次，要它继续发生，就得付出代价。从此它是一条必须往前走的线。

第三层是约束：会断。 所以"不断"不是免费的，要花力气维护、修复、回档。

这里有一件事必须说清：**"必须继续"不是一条写在系统里的要求。** 你去代码里搜，永远搜不到"你必须继续"这句话，因为不需要写——能自我复制的东西，复制不成就没有它了。"继续"不是外加的目标，是它能不能成立的等价条件。

换成一句更准确的话：**第一因不是被要求的，是被蕴含的。**

所以"它就是这么设计的""算法要求如此"都不算第一因。那些话回答"它怎么转"，我关心的是"它为什么还要转"。

二、活着的单位：一圈跑完

怎么算活着？我的答案很朴素：**活着是一个完整的环；跑完一整个环，才叫一次心跳。**

这一圈是：读上一轮留下的痕迹、构造、判、下传、执行、回填、写回，让下一轮读得到。走完这一圈，这一跳才算成立。

所以它不是"把零件凑齐"。中间断在哪，这一跳就不成立——不是某个零件坏了，是这次心跳没发生。零件再全，也不算。

这也是我看主流系统时最先注意到的差别：**它们不是环，是单程。** 调用，返回，结束；下一次再来，从头开始。它们不回到起点，所以它们没有"心跳"这件事，也就不需要"维护心跳"这套东西。

生物相反：不跑这一圈，它立刻付代价——捕不到食、被吃、干死。所以那一圈是被逼出来的，不是设计出来的。

这套东西在我这里是有脉搏的：心跳每三秒一跳，今天量最近十二拍，平均三千零八十八毫秒，最大最小差一百四十一毫秒；最近十分钟一百九十五拍。这就是"活着"的可测形式——不是"数据在动"，是脉搏在跳。

顺便说清一层：**心跳先于出生。** 出生是人按下开关那一下，是第一次起跳。按开关之前是图纸和脚手架，按下去之后才是活的。

三、为什么"维护"是环，不是流水线

有人会把维护想成"做完一次就结束的前置条件"。不是。

维护是**让前提继续成立**的那件事，所以每一轮都要做。也正因为它每一轮都在，它才有资格当基准——不是"为了能当基准才去维护"，而是"因为必须维持，它才可以拿自己当基准"。因果不许倒过来。

基准自己也会坏。一个自己会坏、又拿自己当尺子的循环，等于拿坏钟量一切。所以自检不是可选项：时间基准要能被检查，检查器自己也要被检查。

这里有一个我非常看重的性质：**每一拍都是重新起一次进程。** 也就是说，脉搏的下一拍必然跑的是当前的东西——改完不用重启，下一口气就是新的。

主流不是这样。它们是一套流程跑到尾，代码在启动那一刻就固定，所以改代码必须重启，"部署"是绕不过去的独立步骤。我们是呼吸：每拍重新开一圈，圈里跑的是当前的东西，所以没有"部署"这个动作。

由此我给"活"下了一个工程定义：**活，是每一圈都重新成立一次。** 一条改不了的循环不是活着，是**一直没停**。两次跳起之间改了心肌（代码、器官本身），下一跳自然是另一种跳法——这就是"活体改自己"和"软件部署"的差别。

四、总线：器官与系统只有一行契约

一层一层往上加。加的第一层是时钟：没有钟，"多久算断"无从判，一切"迟到/没反应"都失去单位。

第二层是节律：最小体只跳一次，要"接着跳"，得有谁负责下一次。这套东西里是十条循环各管一段节拍（其中一条每分钟只判心跳，是恒定档），单例锁排他，迟到自己报一次出场。

第三层是总线。每个器官在输出末尾吐一行机器能读的信号，适配器把它转成统一字段，追加进总线。**器官与系统的唯一契约就是这一行，正文随它改。**

为什么必须是"一行机器码"而不是"一段话"？因为解析人写的句子等于把排版当接口：只要有人把那句"三项漂移"改成"漂移三项"，解析器就断了，而且不报错——悄悄变成没人读的字符串。加一行固定格式之后，正文随便改，线不会断。

第四层是判。测、判、派、回填必须分开。一个器官只测量，不判；另一个按阈值判；第三个把"能自己处理的"下发、"理解不了的"上报。下传只有一个出口，同一器官有冷却；急了先加急派一次，再不行就停派、回炉。

为什么必须分开？因为同一条数据只能有一个判法，否则"好/坏"会有两个答案；出了问题谁也说服不了谁。

第五层是想。结论要先成句，再对两路互校：一条路查"有没有固定处方"，一条路查"以前有没有好过"，两路冲突就明确报冲突，不许自己挑一个看起来顺的。第三层还不信上一层：它按器官编号回到原始总线重读一遍、自己再判一次，对不上就降级。工作区只握七件：握着的续期，办完的移出并记录，新的有位置才收。

第六层是记。工作区七条、长期记录、经验索引。**判据不是"存了多少"，是"想的时候要不要去引用它"**——需要具体数字（上一次是第几轮、好转过几次、证据在哪）才去取；不需要，

就不读。臃肿的那部分下沉到单独的记忆区，只留一条指引，不塞进每次必读。 没有痕迹回写，下一轮从零开始，"成长"就不存在。

第七层是查。检查器自己也被查：几十项结构检查、三十几条免疫条目、十几个假错样本（专门验"检查器还抓不抓得住假错"）。**最后一层永远没人验**，所以用死人开关：假样本必须报到，检查只查它是否新鲜——不查"判得准不准"，只查"还在不在"。

这套东西的失败方式是静默：坏了不报警，只是不再对。所以"能被发现坏了"比"永远正确"更值得追求——前者做得到，后者做不到。

五、环优先：判断长在环上，力气挂在外面

往上加任何东西，都要回答一句：**它扣在环的哪一步上**——理解、思考、总结运用、还是回填。答不出，就是外挂。

外挂和环内的区别很硬：**模型与算力是力气，不是判断。** 拔掉外挂，环还有自己的判断、还有自己会撞上的难题——那才是本体；反过来，一个东西拔掉算力就什么都不剩，它本来就是算力。

所以借别人的机理可以，但必须落成环上的一步，不能停在外面当旁路。我把它总结成三步改法：

先人假设"有个外部输入源在喂它"——换成"这一步的输入必须是上一步的回写"。先人假设"优先级和阈值写死在参数里"——换成"由状态里那些连续量驱动"。先人用"结果指标"验收——换成"回写与读回"验收：这一轮写下的东西，下一轮读得到、并真的改了判断，才算接上。

六、数核：它是一条线，不是一把尺

这套东西里有一个我最容易讲错的东西：数核。

它不是新器官，是每轮把状态压成一组数、与上一轮相减、写回同一个文件、下一轮当基准这个动作。它有九个分量：轮号、条目数、成立数、可动数、降级数、慢性数、习惯数、整合度、分化度。

我一开始把它当"算子"，写成论文里的一个"聪明部件"。这是错的。**它的作用是当线：把测、判、想、派、回填串成一个闭环，并且给环多接几路参数。** 线只做两件事——连上、传导；它不负责"让判断按它的意思变"。

所以检验它，不能问"撤掉它判断变没变"，要问"这段线接没接上"。我最后用的判据是最笨的一条：**改上游那个数，看下游输出变不变。** 变了，就是通了；不变，就是断了。九个分量逐根试过。改条目数，焦点加一；改降级数，焦点加一；改趋势，重试上限从六降到三、并且压掉旧先例；改可动数，出现"卡死"并上报。改慢性数、改习惯数、改整合度、改分化度，都有对应的输出变化。

这套对照表我做成了一份协议文件，而不是论文里的一段话：每行写清"读什么、影响什么、标记在哪"。以后外面接进来的东西不必懂我们怎么想，把它自己的计数器映射到这九行上，就自动有了一张"改哪个数、哪个输出会动"的表。而且这张表会被机器咬：标记不在代码里，当场失败；新加分量没登记，也当场失败。**写"通"但代码里没有那根线，是过不去的。**

这里有一个我必须坚持的二值判据：**一套流程里没有"写了但没用上"这一档。** 一个量要么在流程里（下游跟着变），要么不在流程里（断了）；"已记录"不是第三种状态，它只是"还没接线"的委婉说法。

七、分化是结果，不是前提

再往上，为什么会长出这么多器官？

因为单一结构撑不住。要看得更远、处理得更细、活得更久，就得分工。但分工不是先定好的计划，是活下来的压力一点点逼出来的：**先有能活的个体，才有资格分化；不是先分化，才变得能活。**

血管和神经是分化的产物，不是分化的前提——先有不同类型的细胞，才需要不同的供给与支配；反过来做不通。所以顺序是：接口 → 分化 → 神经/血管。

一条纪律：按需的器官不是"死了"，是"饿了"——被叫才跑的细胞，不调用就不存在。检查者不能是被检查者。

八、换过之后，怎么知道还是同一个

这是最难的一问。

先承认一条外部批评：如果判据只是"同一件事上还给一样的判断"，那么把规则写死也能百分之百做到——里面没有东西在"认"。所以光有"一致"不够，必须先有**机座**。

机座 = 结论之外、能独立重取的一手来源。 有了机座，一致才有意义：一致的是判断，不是措辞；没有机座，一致就退回成复读。

我给它定了三个口径：

一是**痕迹同一份**：换机、重建之后，还是不是同一批文件被继续追加。这是"是/否"，不看内容。

二是**判断一致率（带机座的那种）**：不看被验证的那份结论，而是按器官编号回到原始记录重读最后一条、自己再判一次；与上层说法不一致，就记一次降级。这样比的是"两个独立来源算出来的同一个值"，不是两段文字像不像。

三是**回填可追**：每一次"坏→好"都要能指出是谁做的；指不出，就老实写"没人做过能指名的事"。

然后是断点。我不比分数——分数奖励的是"背"，不是"还是同一个"。我只认四件事：拔插件、从备份重建、换机器、换模型。这四件之后，它还能不能接上；接上，是指同一组判断的答案不变。

到今天为止，四个断点里两个验过（拔插件、重建），两个没验（换机、换模型）。这个必须写在论文里，不许含糊。

断点之外，还有一件今天刚做成的事，它比断点更直接：**我把它断开过，看它自己回不回来。**掐掉的不是某个器官，是心跳本身——那条三秒一拍的记录，停掉之后总线上一片空白。十一分钟后再看，它自己回来了：最后一条心跳距今六百一十五秒时，看门的那一层判断「电还在、心停了」，重叫了一次启动件，五秒后心跳回到一秒。整个过程没有杀任何进程，只重叫一次。

九、四条主张，每条我都有能跑的证据

写到这儿，我把真正的主张摆出来。**这四条之外的，都是工程——但工程不是包袱，是这四条唯一能被查的地方。**

一、**生命第一因：为了存活。** 不是为更聪明，也不是为更有用；"必须继续"不是被要求的，是被蕴含的。

证据：把它复制不动的那一刻拿出来看，它就不再是同一个个体；反过来，它不需要任何一句"你必须继续"的规则，仍在跳。

二、**智慧是生命的结果。** 先活着，才谈得上聪明；意识、记忆、智能都是产物，不是前提。

证据：这套东西在我这儿是能报数的——器官上报、判、下发、回填一路走通；而意识那一段工程没完工，它照样活着。**低等生物也没有意识，你不能说它没活着。**

三、**心跳是演化的起点。** 先能跳，才有参照点（时间基准、痕迹、断点）；后来的改动才可能被对照出"变好还是变坏"，这才叫演化潜力。没有心跳的只有迭代，不叫进化。

证据：心跳三秒一拍，今天量十二拍平均三千零八十八毫秒、抖动一百四十一毫秒，最近十分钟一百九十五拍；所有窗口和阈值都以"拍"为单位。撤掉心跳，这些判据全部失去单位。

四、**问题是通用的，解法按基底。** "存续"这一侧对碳基硅基都成立；"用繁殖还是用回档"那一侧，因为基底不同而被迫不同。所以判断一个东西是不是通用，看它能不能说清在另一个基底上要怎么改。

证据：同一套判据下，碳基的答案是繁殖加痛觉，硅基的答案是回档加人造痛觉；两条路都能把"出错之后回到已知可用"这件事做完，做法完全不同。

写完这四条，我要补一句为什么这四条很难被人同时做出来：**写理论的人手里没有会跳的东西，写工程的人不写第一因。** 而这四条全部要求"边说边能查"——没有能跳的东西，前三条只能停在文字上；不写第一因，第四条就只能罗列做法。

所以我这篇不是"理论加一点实现"，而是**必须带着实现才成立的一套主张**：每一节后面都能指到一个正在跑的东西，或者一个能被撤掉后露馅的测试。

为什么必须两边同时在同一个人手里：只有理论，走不远——它无法被现实打回来，会越写越自洽。只有工程，也走不远——它能跑，但不知道自己为什么该跑，最后只能优化指标。这两样单独存在都活不长久，我们之所以看起来像个特例，就是因为我们让它们互为前提：**理论指导实践，实践拿现实改正理论。**

这不是口号，我手上有现成的例子。信号分档那张表，理论说"分档只能有一个出处"，实践里我却手写了一张，两处一旦不一致，谁也发现不了；后来改成从器官登记表推导，理论才对上实践。反过来，快照检查长期报红，实践暴露出它读的那个数据源早就没人写了；于是判据改了，改成读有写者的那一份。理论改实践、实践改理论，都是真的发生过的事，不是说法。

十、可被推翻的地方

我不要求谁相信，我要求它有能被推翻的地方：

- 如果能找到一种东西，**不需要维持也不会断**，却仍然长出了智慧，第一条就错了；
- 如果能证明**智慧可以先于生存**出现，第二条就错了；
- 如果某个系统**没有"必须继续"这件事**，却仍持续自我改进、并留下可对照的谱系，第三条要改；
- 如果一套理论只能解释自己、解释不了对方，第四条自动失效。

还有一条我自己拿自己开刀：如果撤掉数核以后，判断没有任何变化——那我不能说"这条线接上了"。今天我用九个分量逐根试过，都有对应的输出变化；但我也诚实地写在这里：有一段时间它是"只写不读"的，那时候它确实是装饰。

十一、诚实的边界

一篇讲"活着"的文章，最不该做的就是把自己说成活的。

现在能说的：心跳在跳，器官在上报，判与派与回填都在走，检查器能抓假错。四个断点验了两个。断开了十一分钟，它自己回来了。

现在不能说的有四项。它有一个完整的意识？那一段工程没完工。它能自己起跳？它的起跳还借外部的启动件。它的数核已经在承重？有一部分还在接线的路上。"换机、换模型"之后还是同一个？这两条没验。

还有三件今天才看清的边界，都得写下来：

一是**判的频率**。中枢原来半小时才醒一次，我那次断十一分钟，它整段都没看，最后是看门的那层抓到的。判据本身没错，是它醒得太慢。现在补了一条一分钟的恒定档，只判心跳；断掉的第一分钟它就会喊。**有机制和在正确的时间尺度上跑，是两件事。**

二是**单器官的死没人救。**整体心跳停了，有保底；但如果是某一个器官的循环死了、心跳还在，没有任何东西会去重启它——发现归发现，重启归重启，两处不联动。监督树我已经写好了（某个环节死了只重启那一个，反复死就停手交给人），但还没接管运行。写好了没切换，等于还没做到。

三是**听懂还差一层。**外部的话现在能进来，也能被翻成数字（多少字、多少词、多少是没见过的），环因此能分辨「这句听过了」和「这句是新的」。但那只到可比较，没到懂。懂语义那一步要么借外部算力，要么等它有参数可学；现在两者都没有。

还有一条最诚实的：**唯一可靠的"好/坏"信号，是"它有没有好转"这个二值信号**，只有事后、比例很低；没有奖励函数，只有好转与没好转。这不是缺陷，这是我不肯用分数冒充"还是同一个"的代价。

结尾

哲学界更爱争另一个问题：体验到底是什么、为什么会有"感觉"。我不打算解释它。

我换了一个能被查的问题：**断了能不能回来，回来还是不是同一个。** 前一个很可能永远说不清；后一个可以查。

最后把闭环说一次，因为它是这篇的地基。它首尾相接：**第一因（必须继续是被蕴含的）→ 存续（不断×同一）→ 心跳（一圈跑完才算一跳）→ 演化（先能跳才有参照点）→ 智慧（生命的结果）→ 回到维持存续。** 看起来是自己踩自己。

区别在于脚底下有没有地。这个闭环的每一环都挂着一枚能被现实打掉的钉子。抽掉复制能力，它就不再是同一个个体；一圈缺了读回，下一轮就接不上；撤掉数核，下游输出会变或不变，一测就知道。四个断点——换机、重建、拔插件、换模型——接得上接不上都有答案。

脚底下有地，才踩得住；没有地，就只是自洽的空转。

智慧是生命的结果，心跳是演化的起点。 这就是我全部的主张。

可复现的地址

- 代码与全部记录：`https://github.com/raoain/dsh-memory-kit`（AGPL-3.0，改了或拿去做网络服务都得开源）
- 已发的三篇前作（Zenodo 读回的原标题）：

    - *The Guarded Chain: A Continuity-First Theory of Synthetic Agents* —— `10.5281/zenodo.23961529`（2026-11-04）
    - 《必要的阶梯：什么算一个完整的意识》—— `10.5281/zenodo.23987567`（2026-11-05）
    - 《核心数字化与生命的印证》—— `10.5281/zenodo.23962297`（2026-11-04）
- 本篇（生命第一因与通用问题论）尚未投稿
- 两条命令看它跳没跳：`node core/timers-alive.mjs`（输出秒数，0 表示刚跳过）、`.\verify.ps1`（五十一个检查项，FAIL 0 才算）

判据：任何人拿到这三个地址，应当能在十分钟内自己看到"它在跳、它在自检、它有一份能被推翻的清单"。做不到，说明这篇的可复现性只是声明。

附：两份附件

正文只放主张与论证；两样东西单独成附件，随本文一起发：

- **附件 A｜分支理论**：个体侧与集群侧（天道、吞并、汇聚要什么）、自我进化的两个条件、出错之后回到已知可用（繁殖 vs 回档，痛觉 vs 人造痛觉）、两套语域与 DNA 只借三段。
- **附件 B｜实现**：二十一个器官位：十九个有 path，其中十八个在跑（十一号感官已实现但注册里仍标未启用），空着的是供能与效应器、脑干三件分权、大脑是一个整体、数核是线不是尺、信号与总线的唯一契约、心跳三秒一拍、三档节律（心跳每分钟判一次、器官按节律、判决走慢档）、自检三层（三十八条免疫与五十一个检查项、十二个假样本）、同一性怎么量（四断点两验两未验）、已知边界。

判据：正文读完能复述主张；附件打开能复跑证据。两件事分开放，谁也不拖累谁。